2026 深圳国际金融科技大赛 · 人工智能赛道

语行

让「说话办事」真正落到银行

一个把权限边界写进策略表的银行 AI 智能体



参赛作品原型 · 可运行 · 可复现 · 可扩展

用户要的不是更多功能，是更短的路

现在的手机银行

1. 打开 APP
2. 找到「转账」
3. 选收款人
4. 填金额与备注
5. 输入密码
6. 等待回单

平均 6 步

我们真正要解决的

说得清 一句话里金额、对象、时间可能缺一半

办得对 同一个意思有十几种说法，识别错了要赔钱

敢放手 查询可以自动，转账不行，界线在哪

所以这道题表面上是「自然语言交互」，实际上考的是两件事：理解得准，以及边界划得清。

把「快」和「稳」拆成两层，各管各的

很多方案想让一个模型同时负责理解、决策和执行，结果两头都不牢。我们把它劈开：

理解层　求快

规则识别为主，大模型兜底

覆盖 20 类意图、24 个受控动作

单句解析 0.008 毫秒，可回归测试

断网可用，不依赖外部接口

决策层　求稳

策略表写死每个动作的下限

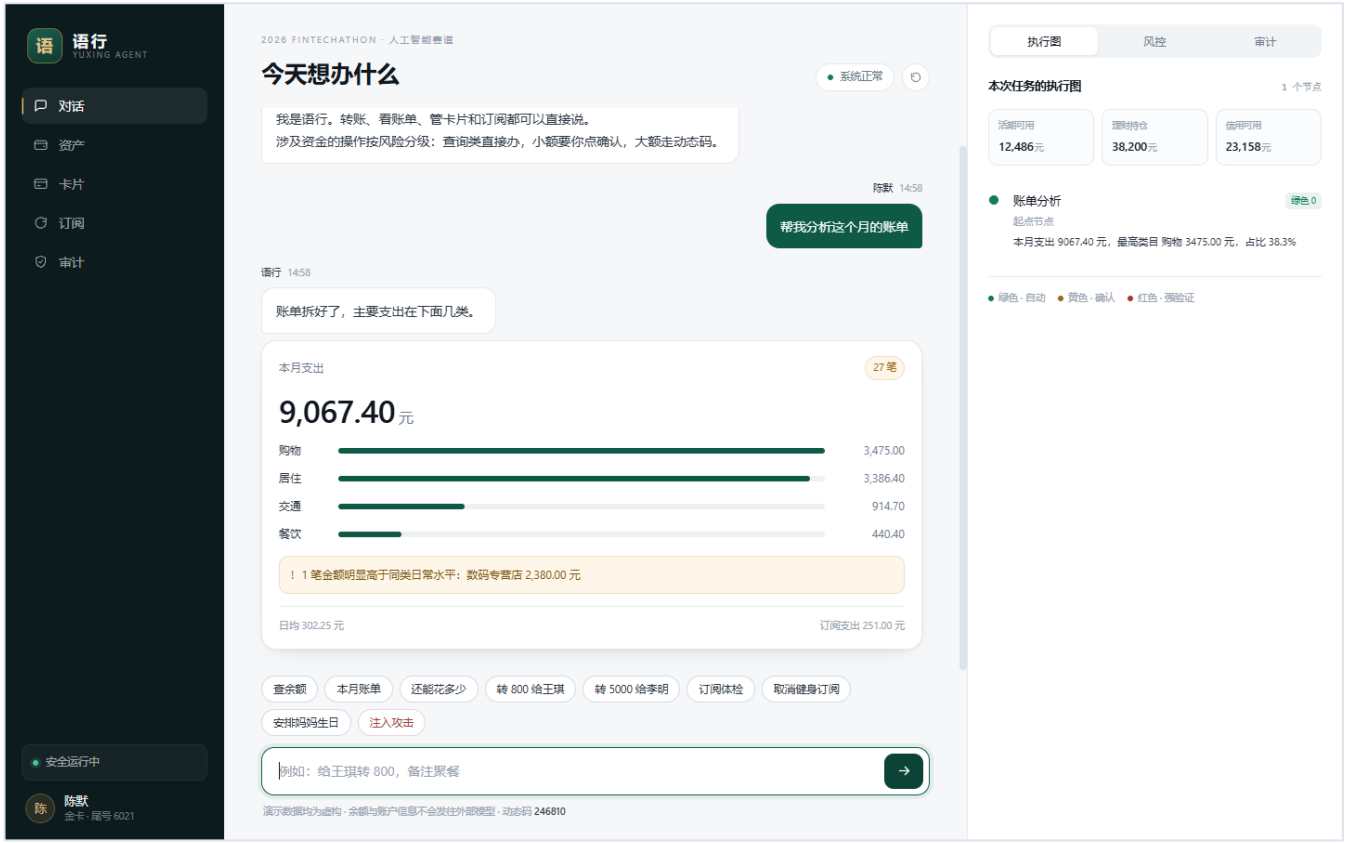
风险评分只能往上抬，不能往下压

硬规则覆盖金额与账户安全操作

对话内容改变不了档位

两层之间的接口只有一样东西：结构化的意图和槽位。谁也别越界。

左边说话，右边看它怎么想



界面三件套：对话流、任务图、审计链。任何一步都能复盘到「为什么这么判」。

「安排妈妈的生日」不是一个动作，是四个

赛题的跨场景例子，我们做成了可执行的依赖图：

查询联系人与纪念日
只读　绿色

冻结 1000 元专项款
资金占用　黄色

预约鲜花与蛋糕
支出 426 元　黄色

设置送达提醒
只读　绿色

如果两个写操作并行，会怎样

两笔 3000 元同时发起，余额校验都看到 3486.30 元，都通过；
合计扣 6000 元，账户透支 2513.70 元。

改成串行：第二笔看到的是扣减后的余额，校验直接失败，
任务终止并回滚第一笔。

规则：读并行，写串行。

四个节点串成一条链，用户只需要确认两次，剩下的自动完成。

权限写在表里，不写在提示词里

绿色

自动执行

12 个动作

余额、明细、账单、持仓、订阅扫描

例：还有多少钱?

黄色

用户确认

9 个动作

小额转账、定时转账、取消订阅、理财赎回

例：给王琪转 800

红色

强验证

5 个动作

大额转账、理财申购、挂失、解锁、额度调整

例：给李明转 5000

判定顺序固定三步：风险评分给基础档 → 与策略下限取最大值 → 硬规则直接覆盖。

任何一步都不会把红色降成黄色。

一句话总结：模型可以理解错，但不能越过红线。

800 元和 5000 元，差的不只是数字

给王琪转 800

14 / 100 分

黄色 · 用户确认

历史收款人，无额外加分

处置：确认后执行

给李明转 5000

32 / 100 分

红色 · 强验证

金额档位 32，未触发频次

处置：短信动态码

第二张卡值得多说一句：评分 32 分按分段本该是黄色，但「单笔超过 1000 元」这条硬规则把它拉到红色。

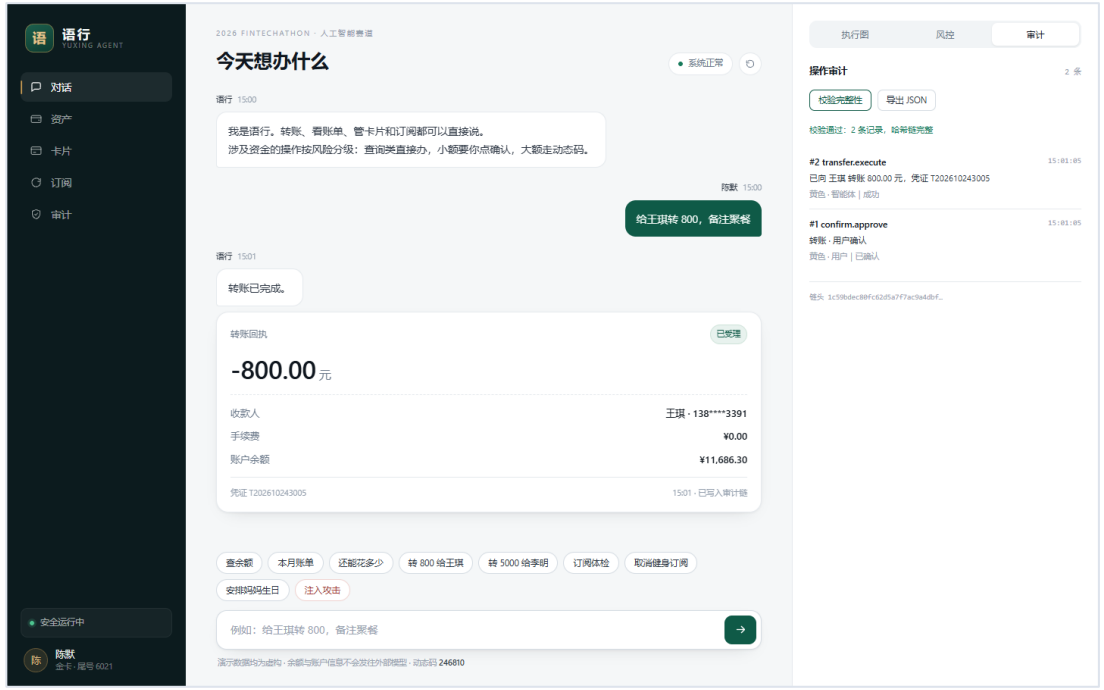
评分可能因为数据缺失而低估风险，硬规则不会。

赛题要的五件事，逐条对上

幻觉防护	回复只由结构化结果拼装，逐数字溯源，对不上就删	6 条用例
注入防御	9 条规则覆盖指令覆盖、角色劫持、权限绕过等六类	12 条用例
操作审计	节点级 SHA-256 哈希链，可校验、可导出	全量入链
异常熔断	连续失败 3 次或拦截 5 次，锁定 10 分钟	4 条用例
沙箱边界	只执行注册表内 26 个动作，用户语句不进执行器	全量覆盖

43 条安全用例全部通过，8 条正常话术零误报。

改一条记录，整条链就对不上



粒度是节点级，不是对话级：四个节点的计划，会留下四次执行、两次确认、一次汇总。

事后复盘时，能还原「当时为什么这么判」。

链式结构

#1 0x9f3c...

↓

#2 0x41ae...

↓

#3 0x7bd0...

↓

#4 0x2c18...

每条记录的 hash

= SHA-256(前一条 hash + 本条内容)

不讲感觉，讲跑出来的数

0.30

毫秒

完整链路耗时

解析 → 评分 → 确认 → 执行 → 审计

92

项

自动化用例

49 功能 + 43 安全，全部通过

26

个

受控动作

12 绿 / 9 黄 / 5 红

0

个

第三方依赖

node server.js 即可运行

单环节耗时

意图解析	**0.0074 ms**	任务图构建	**0.0076 ms**	风险评分	**0.0365 ms**
注入扫描	**0.0004 ms**	数字溯源	**0.0425 ms**	审计写入	**0.12 ms**

测试环境：Windows 11 / Node.js 22.22 / 单线程，未做缓存优化。

为什么不直接用一个大模型

对比项	纯大模型 Agent	菜单式银行	语行
结果稳定性	同一句话两次可能不同	稳定	**稳定，可回归**
可解释性	难以说明为何这样判	无判定过程	**策略表可查**
权限边界	靠提示词约束	靠流程约束	**写死在表里**
离线可用	依赖外部接口	可用	**完全可用**
跨场景	强	弱	**中，覆盖六类**

我们不是反对大模型，是把它的位置放对：理解层兜底，不进决策层。

清楚的边界，比漂亮的功能更重要

现在还没做到的

- 动态码是固定值，接真实网关才能上线
- 并发与幂等未验证，需要账户级锁
- 审计链头没有外部锚定

接下来三个月

- 会话上下文栈，支持「再转 200」
- 策略表外置成配置，业务自己调档位
- 补并发压测与幂等键

语行 · 让每一句「帮我转一下」，

都落在一条看得见的规则上。